FIUBA · CEIA · ANÁLISIS DE DATOS 4B 2026 · TRABAJO PRÁCTICO INTEGRADOR

¿Qué delitos terminan en arresto?

Análisis exploratorio y preparación de datos para un modelo de clasificación sobre los crímenes reportados en Chicago durante 2015.

Santiago Acevedo · Nicolás Hasbún · Sofía Picasso

264.910
delitos reportados

22
variables originales

26,5%
terminaron en arresto

2,6%
sin coordenadas

01 El dataset y el problema

Chicago Data Portal · 2015

Qué hay en los datos

Cada fila es un delito reportado: qué pasó, dónde, cuándo y si hubo arresto. Casi todas las variables son categóricas; las zonas (Beat, District, Ward) usan números pero no son cantidades.

11	categóricas nominales (tipo, lugar, zonas)
4	cuantitativas continuas (coordenadas)
3	temporales (fecha, año, actualización)
2	binarias (Arrest, Domestic)
2	identificadores (ID, Case Number)

Problema de ML: clasificación binaria

Dado un delito reportado, predecir si termina en arresto. Sirve para entender qué características de un hecho se asocian a su resolución y en qué zonas o tipos de delito la tasa es más baja.

TARGET **Arrest** True / False

73,5% sin arresto 26,5%

Desbalance moderado. Entropía normalizada de Arrest: 0,83 (máximo 1).

02 Qué muestran los datos

EDA

Tasa de arresto por tipo de delito

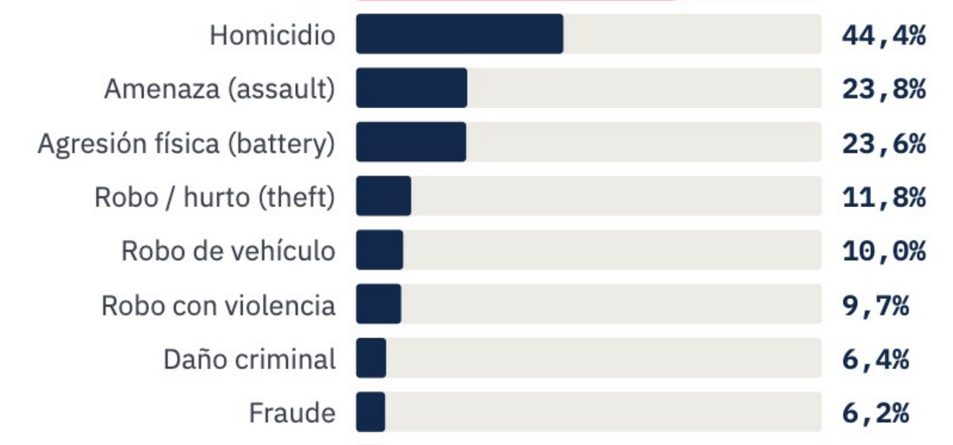

Los delitos **“reactivos”** se registran en el momento de la detención, por eso rozan el 100%. Los que se denuncian después (robos, fraudes, daños) casi nunca terminan en arresto.

Delitos registrados por mes

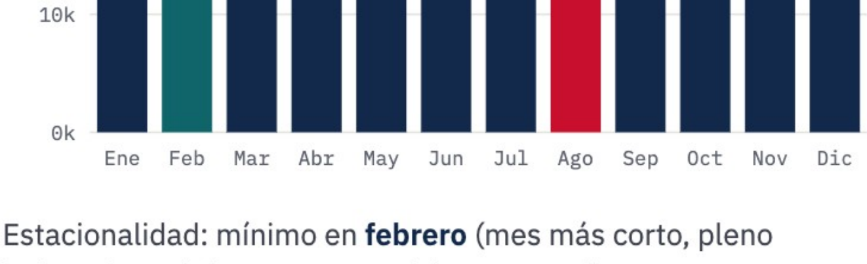

Estacionalidad: mínimo en **febrero** (mes más corto, pleno invierno) y máximo en **agosto** (pleno verano).

Delitos por día del mes: el día 1 sobresale

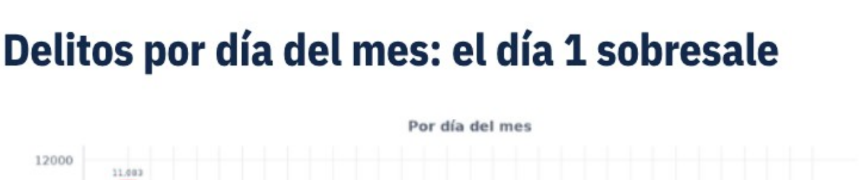

El día 1 suma **11.083** registros contra **8.461** de promedio en los otros días. Los 6 días outliers por IQR (límite: 938 delitos por día) son todos días 1, encabezados por el **1 de enero** con 1.300.

El 31 es bajo porque solo 7 meses tienen ese día.

Registros por día de la semana y hora

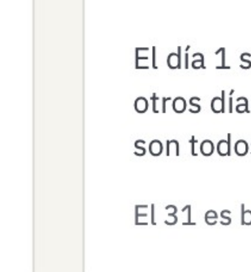

La madrugada (3 a 6 h) es la franja más tranquila, salvo los fines de semana. Se destacan el **mediodía** todos los días y la tarde del viernes. La columna de las **0 h** resalta en toda la semana: es la hora “default”.

Hora “default”: 00:00

13.136 registros a las 00 h contra **10.947** de promedio en otras horas. El minuto 00 concentra el **34,5%** (uniforme: 1,7%).

Concentración

Los 3 tipos más frecuentes suman el **50,9%** de los delitos y los 10 primeros el **91,7%**. Muchas categorías son raras.

03 ¿Dónde ocurren los delitos?

EDA espacial

Densidad de delitos

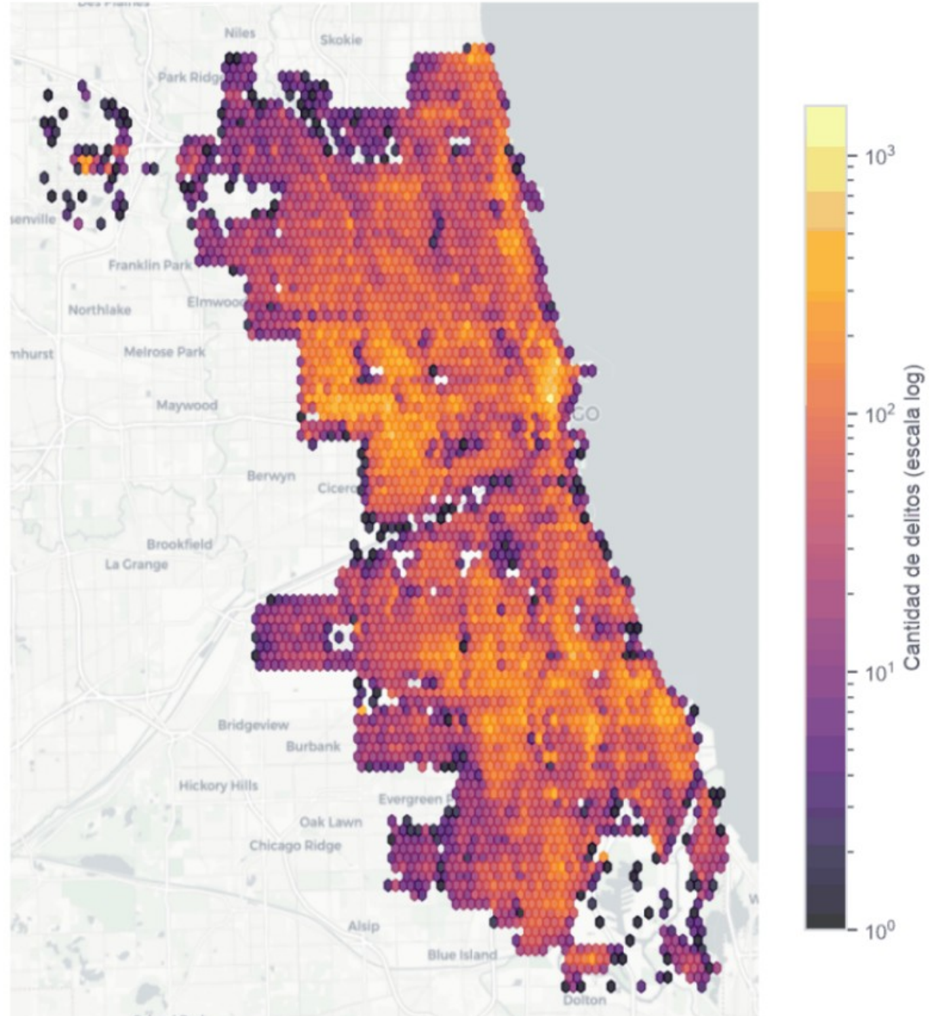

Los delitos se concentran en el centro y en el oeste y sur de la ciudad. Ninguna coordenada cae fuera de Chicago (**0** registros fuera del área).

Cuatro formas de dividir la ciudad

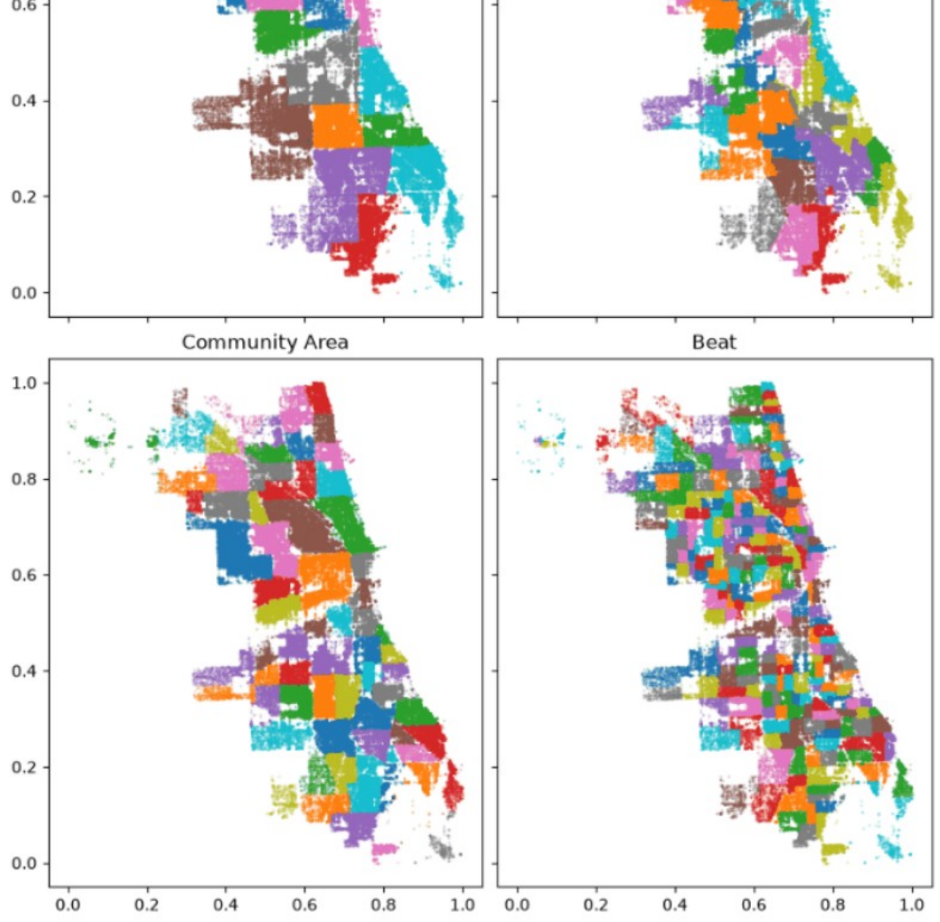

Las cuatro divisiones cubren el mismo territorio con distinta resolución. **Beat** es la más fina y queda casi siempre dentro de un **District** (V = 0,98; solo 30 de 274 beats cruzan de distrito).

Un outlier real: Austin

La Community Area 25 (Austin) registra **17.436** delitos, contra **258** del área con menos y una mediana de **2.377**. Es el único outlier por IQR (límite: 10.561), pero no es un error: en 2015 era el área más poblada de Chicago. Se conserva.

04 Calidad de datos

faltantes · duplicados · inconsistencias

PROBLEMA	AFECTADOS	TIPO	CAUSA	TRATAMIENTO
Coordenadas faltantes	7.001 · 2,6%	MAR / MNAR	Ocultas por privacidad (delitos sexuales y contra menores) o sin lugar físico (fraudes)	Media de X/Y del Beat (train → test) + indicador coord_faltante
Location Description nula	620 · 0,2%	MAR / ESTRUCTURAL	616 de 620 (99,35%) son fraudes financieros u online	Nueva categoría ONLINE/UNKNOWN
Ward / Community Area	2 y 14	MCAR APARENTE	Falla puntual de geocodificación en los Beats 1614 y 1654	Moda del Beat (train → test)
Hora 00:00 exacta	2.923	FALTANTE ENCUBIERTO	Hora “default” cargada cuando no se conoce la real; tasa de arresto 6,6% vs 26,5% global	Indicadores hora_default y fecha_default
Case Number repetido	27 casos · 50 filas	POR DISEÑO	Homicidios múltiples: una fila por víctima	Una fila por caso
CRIM / CRIMINAL SEXUAL ASSAULT	1.467	INCONSISTENCIA	Categoría renombrada entre 2020 y 2021	Unificadas en SEXUAL ASSAULT
Location Description: categorías	140	INCONSISTENCIA	Misma categoría con distinta puntuación	Normalizadas: 140 → 116
District inválido	9	ERROR	Distritos no policiales	District eliminado (redundante con Beat)
NON-CRIMINAL	1	RUIDO	No es un delito	Eliminado

05 Preparación del dataset

limpieza → split → transformación

PASO 01
Eliminar columnas
ID, Updated On (posterior al hecho), Year (constante) y Lat/Lon/Location (redundantes con X/Y).

PASO 02
Deduplicar y limpiar
Una fila por Case Number, SEXUAL ASSAULT unificado y NON-CRIMINAL eliminado: 264.910 → 264.882 filas.

PASO 03
Reducir códigos
FBI Code (26) e IUCR (328) tienen V ≈ 1 con Tipo + Descripción (366): se eliminan.

PASO 04
Reducir geografía
District eliminado: V = 0,98 con Beat; solo 30 de 274 beats cruzan más de un distrito.

PASO 05
Split estratificado 80 / 20
211.905 filas de train y 52.977 de test, ambos con 26,45% de arrestos.

PASO 06
Imputar
Media y moda por Beat, aprendidas en train y aplicadas igual a test: 0 nulos en ambos.

PASO 07
Crear features
Hora, mes, día y día de la semana cíclicos (seno/coseno), Tipo_Desc e indicadores de faltantes.

PASO 08
Codificar y escalar
One-hot (37), target encoding (3), numéricas (10) y binarias (4): 54 features. MinMax en coordenadas.

RESULTADO
Dataset final 54 features
+ target Arrest (label encoding: 0 / 1)

37 One-hot

`Primary Type` `Location Description`

Categorías con menos de 0,5% de los registros agrupadas en una sola. Location Description: 114 categorías → 21 columnas.

3 Target encoding

`Tipo_Desc_te` `Beat_te` `Block_te`

Cada categoría se reemplaza por su tasa de arresto en train, con validación cruzada interna (cv = 5).

10 Numéricas

`X Coordinate` `Y Coordinate` `Hour_sin · cos` `Month_sin · cos` `Weekday_sin · cos` `Day_sin · cos`

Coordenadas con MinMax a [0, 1]. Hora, mes, día de la semana y día del mes con codificación cíclica.

4 Binarias (0 / 1)

`Domestic` `hora_default` `fecha_default` `coord_faltante`

Booleanas: si el hecho es de violencia doméstica, y los indicadores de datos faltantes o “default”.

06 Selección de features

V de Cramér · información mutua

Asociación con Arrest (V de Cramér corregida)

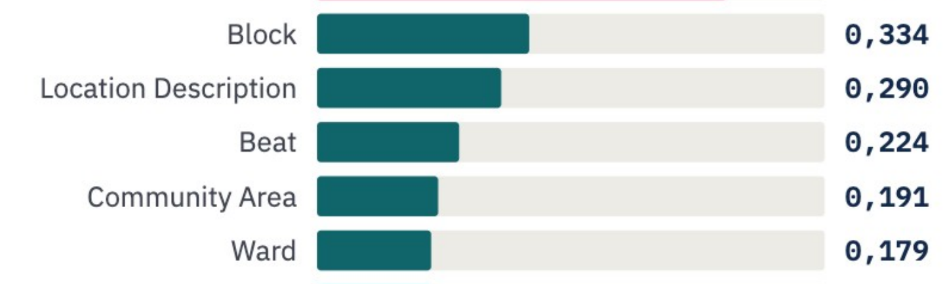

Block concentra ≈ **96%** de la señal de toda la geografía. District es la variable geográfica menos asociada y se elimina.

Información mutua con Arrest

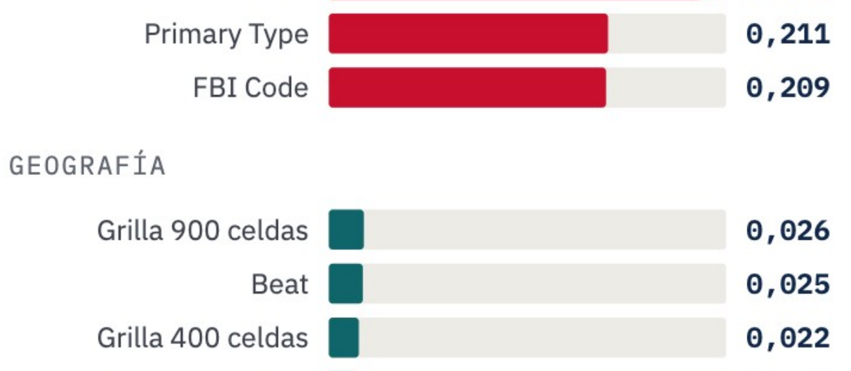

IUCR alcanza **0,281**; la mejor variable geográfica, una grilla de 900 celdas, **0,026**.

07 Balance de clases y reducción de dimensionalidad

Balance de clases: undersampling

211.905	112.104	52.977
train original · 73,5 / 26,5	train balanceado · 50 / 50	test · 73,5 / 26,5

Por qué undersampling: con más de 200 mil filas se conservan más de 100 mil sin inventar datos, como haría el oversampling.

Solo en train: el test refleja la proporción real de arrestos.

PCA

31 / 54	36 / 54	42 / 54
componentes para 70%	componentes para 80%	componentes para 90%

PC1 explica el **5,4%** y PC1 + PC2 el **9,3%**: la varianza está muy repartida.

Ventajas: menos columnas (entrenamiento más rápido) y componentes sin correlación entre sí.

Desventajas: features más difíciles de interpretar, posible pérdida de información sobre el arresto y compresión baja con datos casi todos categóricos.

No se aplica: 54 columnas no es un problema de dimensionalidad.

Conclusiones

1 **El tipo de delito casi define el arresto.**
Los delitos “reactivos” se registran porque hubo una detención: narcóticos 99,97%, prostitución 99,85%. Tipo + Descripción tiene V = 0,733 con el target, contra 0,334 de Block, la mejor variable geográfica.

2 **Los faltantes no son aleatorios.**
Las coordenadas se ocultan para proteger a las víctimas (CRIMINAL SEXUAL ASSAULT: 41,9% sin coordenadas) y los delitos con hora “default” (00:00, cargada cuando no se conoce la hora real) tienen una tasa de arresto de 6,6% contra 26,5% global. Se conservan como indicadores.

3 **Hay mucha redundancia.**
FBI Code e IUCR repiten el tipo de delito (V ≈ 1) y las geografías están anidadas (Beat y District: V = 0,98). Medir la asociación permitió descartar columnas sin perder señal.

4 **PCA no conviene en este dataset.**
PC1 explica solo el 5,4% y hacen falta 36 de 54 componentes para el 80% de la varianza. Con features casi todos categóricos, la compresión es baja.